
Sistemas de Inteligencia Artificial

Aprendizaje No Supervisado

Grupo 02 – ITBA 2024



El equipo



Girod, Joaquín



Ijjas, Christian



Magliotti, Gianfranco



Ferrutti, Francisco

01

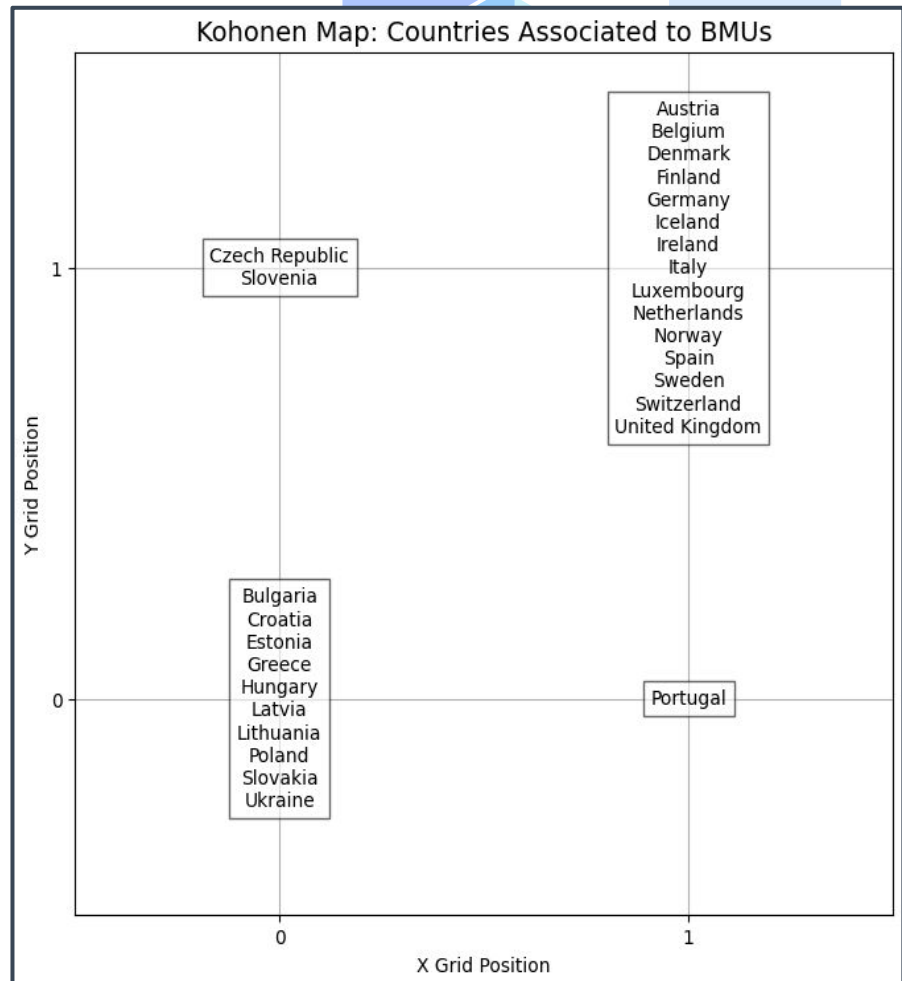
Red de Kohonen



Primera Agrupación

- Agrupación Clásica :
 - Países Desarrollados
 - Países en Vías de Desarrollo
 - Países No Desarrollados
- Reclusión a Europa
- Muy Simple


```
seed = 42
grid_size = 2
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 1000
```



Aumentamos Grid Size

- Ganamos Diferenciación
- No estamos realmente agrupando, intuitivamente bajamos el grid size
- Muchas neuronas inutilizadas

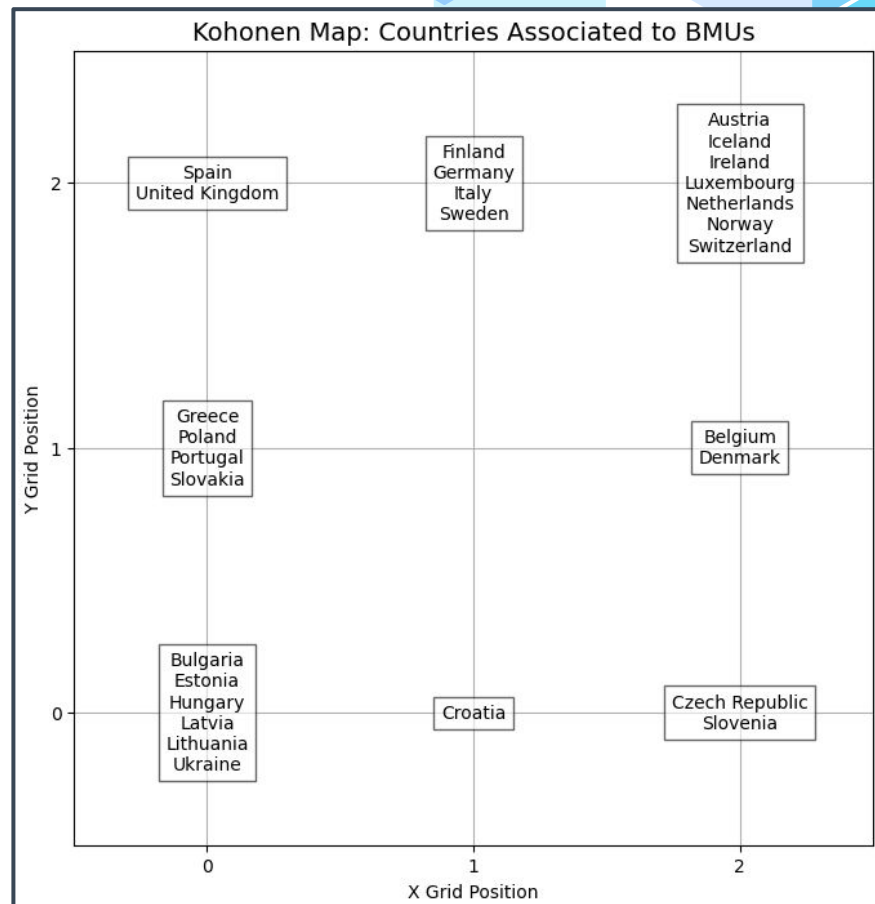
```
seed = 42
grid_size = 10
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 1000
```



Equilibrio

- Agrupación con una cantidad equilibrada de elementos
- Una sola Neurona Muerta
- Atado al Data Set
- Pero no podemos apreciar la distancia entre las neuronas...

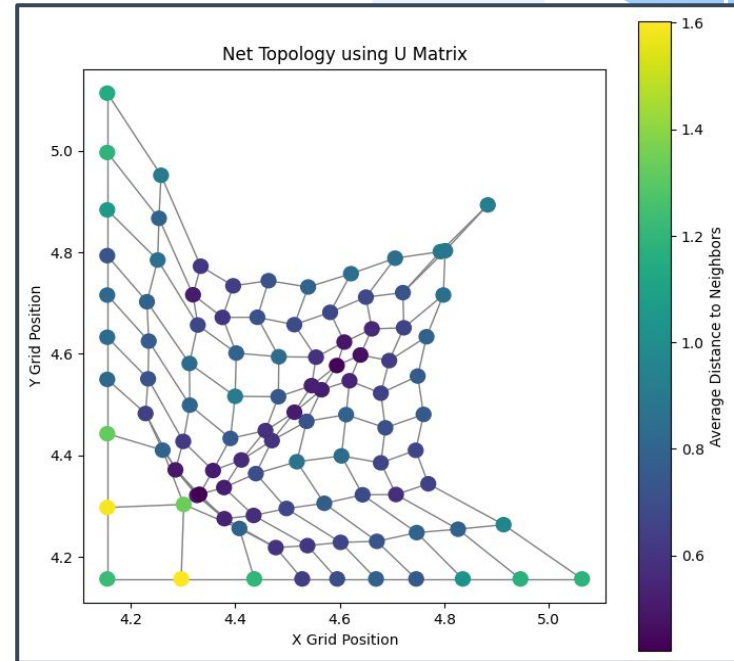
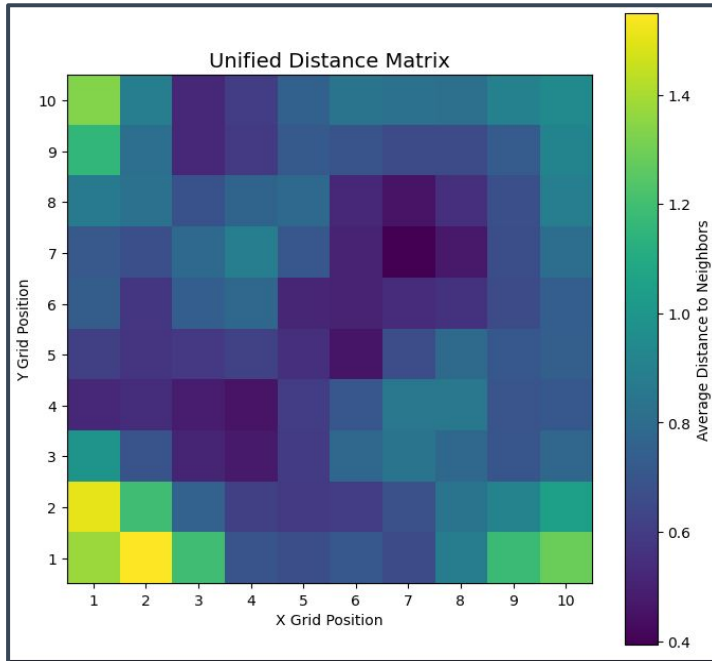
```
seed = 42
grid_size = 3
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 1000
```



Análisis de Distancias


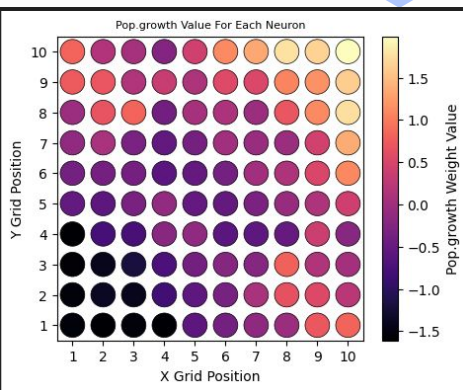
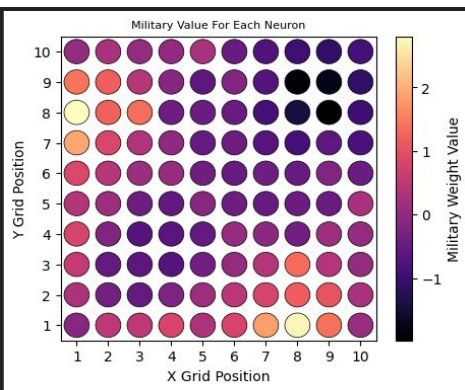
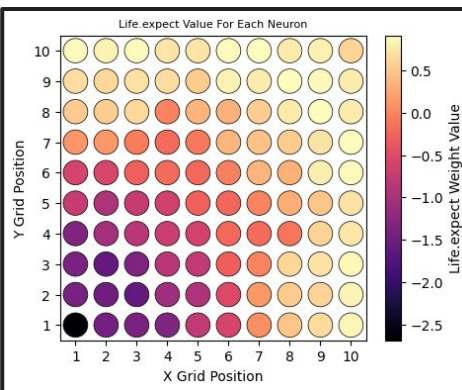


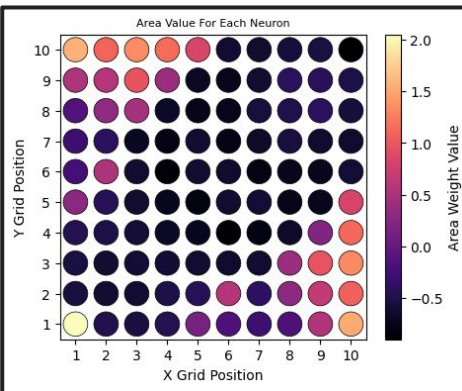
- Usamos **grid_size** 10 para apreciar mejor la topología
- La acumulacion le otorga mayor precisión a la red

```
seed = 42
grid_size = 10
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 1000
```



Análisis de Variables

```
seed = 42
grid_size = 10
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 1000
```



Convergencia


```
SOM 1
seed = 42
grid_size = 10
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 100
```

- La red derecha no logra estabilizarse
- Efecto de los hiperparámetros
- Muy dependiente del último valor utilizado para fitting

```
SOM 2
seed = 42
grid_size = 10
eta = 0.5
eta_fn = constant
initial_radius = 3
radius_fn = constant
sim_fn = euclidean
epochs = 100
```


Iteration: 1

Neuron Locations Across Training Iterations




Iteration: 1

Neuron Locations Across Training Iterations



Errores

- SOM 2 no logra minimizar el error de cuantización
- La red minimiza el error de cuantización al costo del error topográfico
- Un trade-off que vale la pena?




SOM 1
seed = 42
grid_size = 10
eta = 0.5
eta_fn = expo_decay
initial_radius = 3
radius_fn = expo_decay
sim_fn = euclidean
epochs = 100

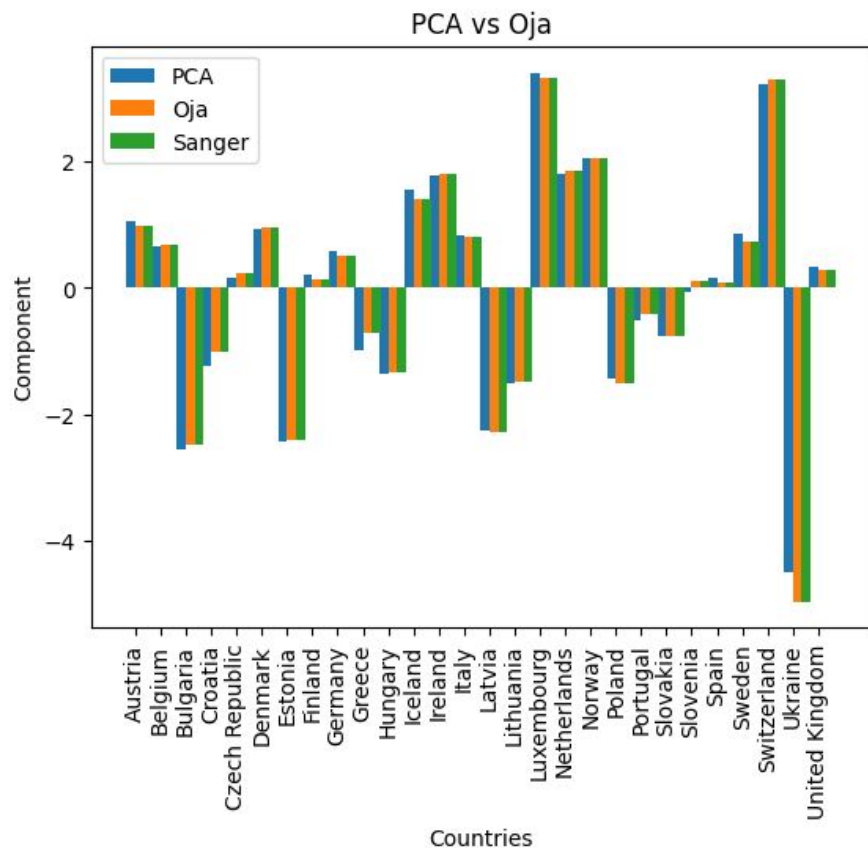
SOM 2
seed = 42
grid_size = 10
eta = 0.5
eta_fn = constant
initial_radius = 3
radius_fn = constant
sim_fn = euclidean
epochs = 100

02

Oja y Sanger




PCA vs Oja vs Sanger






- Seed: 42
- Dividing by epoch
- 1000 epochs
- Learning Rate 0.01

PCA vs Oja vs Sanger: Loadings



- Seed: 42
- Dividing by epoch
- 1000 epochs
- Learning Rate 0.01


PCA vs Sanger: Loadings



- Seed: 42
- Constant eta
- 1000 epochs
- Learning Rate 0.01

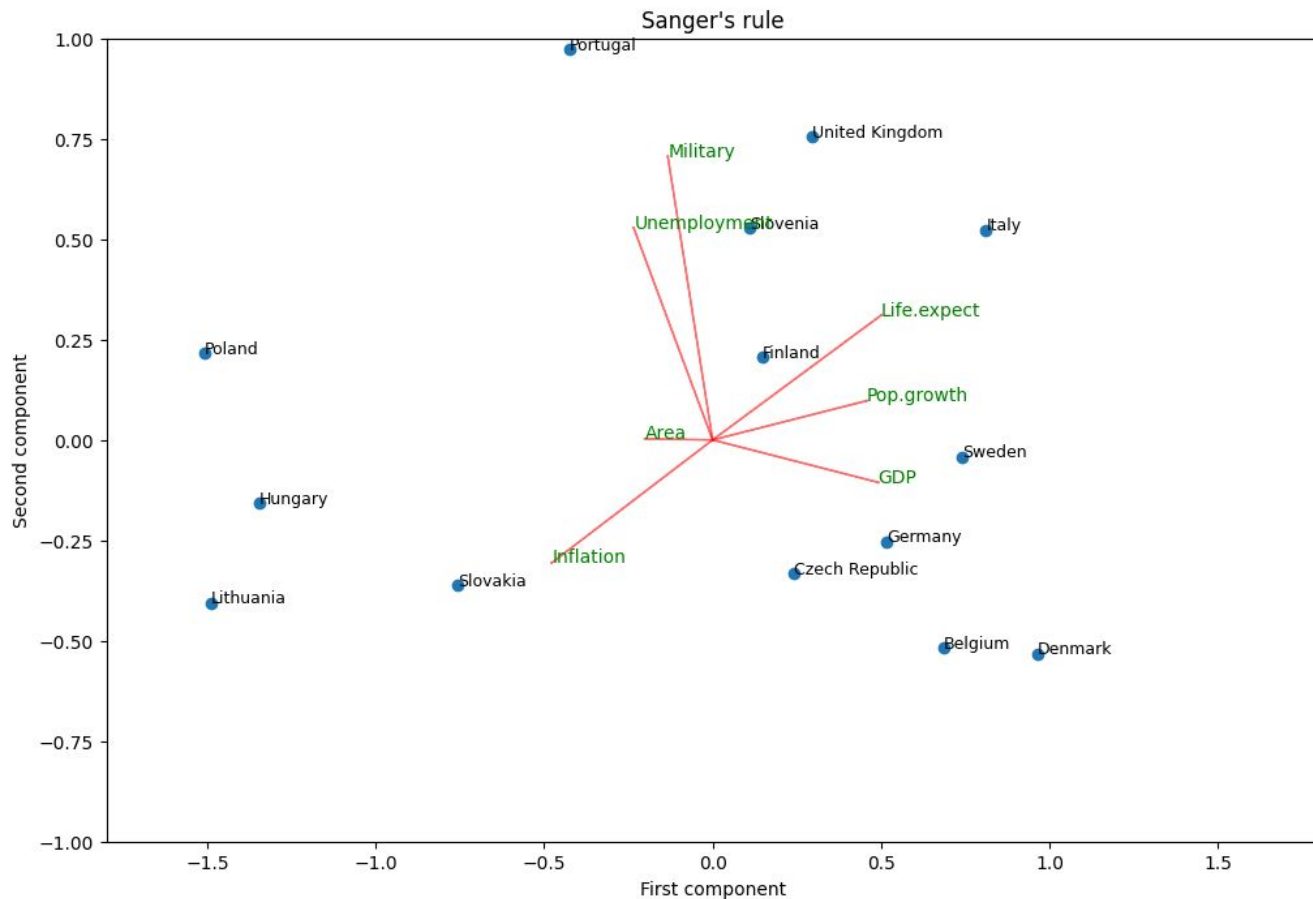
Repaso:

Biplot: PCA




- Zoom in

Biplot: Sanger




- Seed: 42
- Constant eta
- 1000 epochs
- Learning Rate 0.01
- Zoom in

Biplot: Paths




03

Hopfield



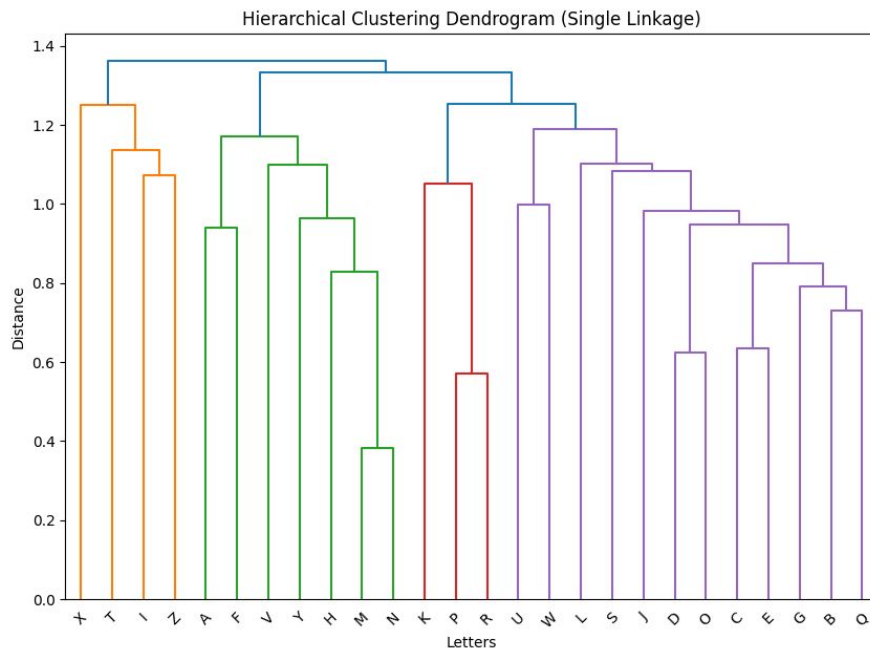
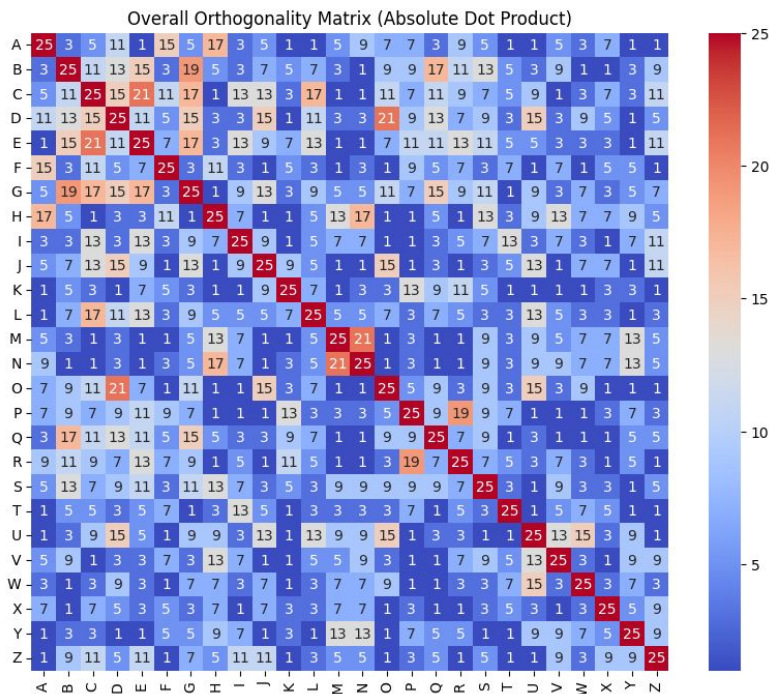

Nuestras Memorias



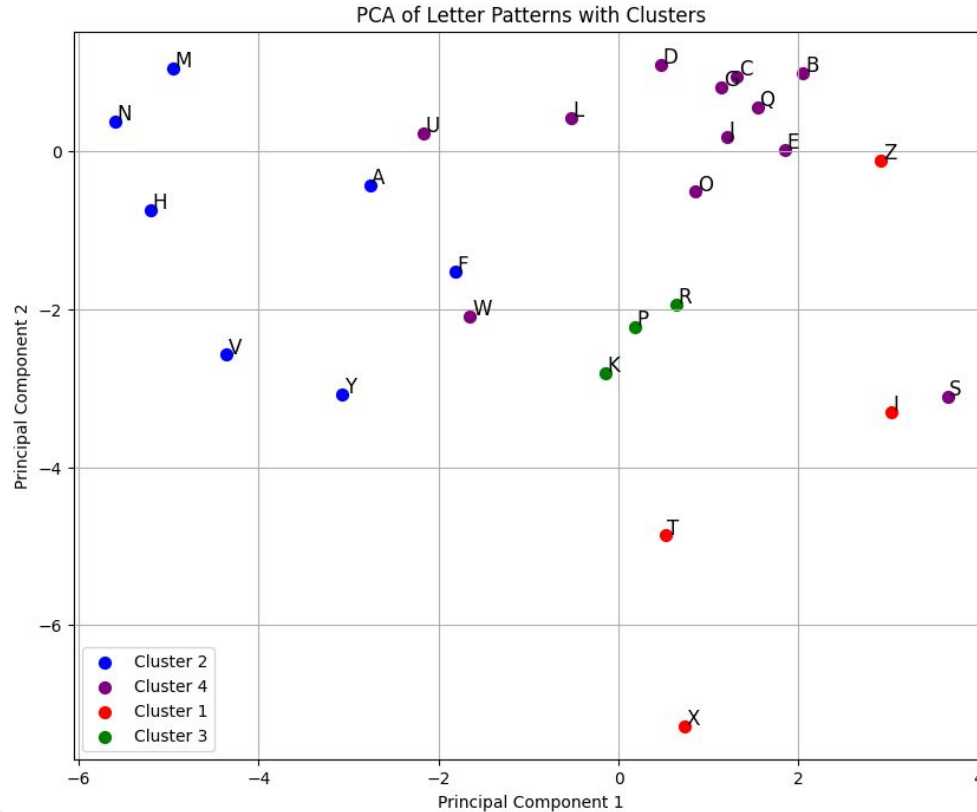
letters_cool.txt

Buenas Memorias

- ¿Cómo se eligen buenas memorias ?



Mejores Memorias



Mejores

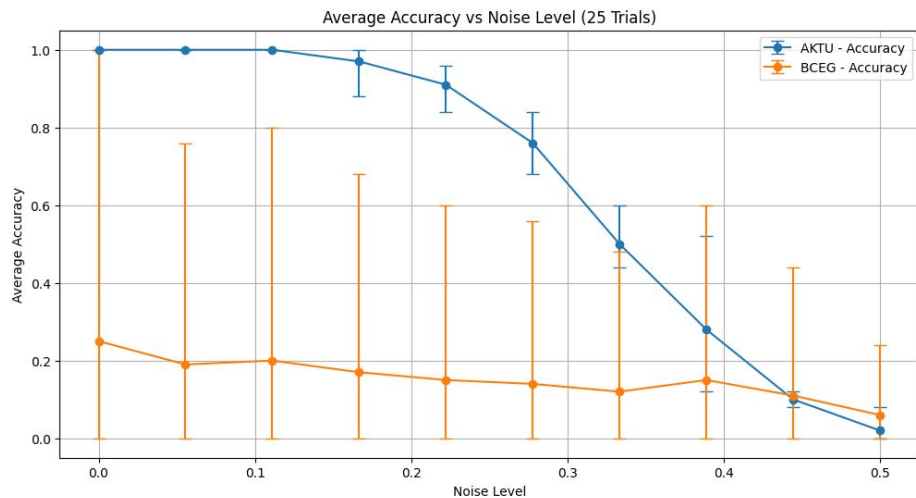

<> medio	grupo	unique_values
1.00	('A', 'K', 'T', 'U')	[1, 1, 1, 1, 1, 1]
1.00	('A', 'K', 'T', 'Z')	[1, 1, 1, 1, 1, 1]
1.00	('A', 'K', 'U', 'Z')	[1, 1, 1, 1, 1, 1]
1.00	('A', 'T', 'U', 'Z')	[1, 1, 1, 1, 1, 1]
1.00	('K', 'T', 'U', 'Z')	[1, 1, 1, 1, 1, 1]
1.33	('A', 'K', 'T', 'Y')	[1, 1, 1, 1, 3, 1]

Peores

16.00	('C', 'D', 'E', 'G')	[15, 21, 17, 11, 15, 17]
16.67	('B', 'C', 'E', 'G')	[11, 15, 19, 21, 17, 17]





Las memorias muy similares generan recuerdos confusos.

Comparando Memorias





Se pone difícil reconstruir patrones

Comparando Memorias



¿Preferimos que haya **uniformidad**?


Comparando Memorias



La media **esconde** datos relevantes


Limitaciones

$$C \cong \frac{n}{2 \log_2 n}$$




Espuriedad




Original - $E = -10.56$




Noisy




Recovered - $E = -8.64$




Original - $E = -27.52$



Noisy





Recovered - $E = -29.76$



Clasificación

- Negación
- CL de N patrones : N impar





$$E(-\xi^\mu) = -\frac{1}{2} \sum_i \sum_j w_{ij} (-\xi_i^\mu) (-\xi_j^\mu)$$

Al simplificar, tenemos:

$$E(-\xi^\mu) = -\frac{1}{2} \sum_i \sum_j w_{ij} \xi_i^\mu \xi_j^\mu = E(\xi^\mu)$$

$$\epsilon_i^{\text{mix}} = \pm \text{sgn}(\pm \epsilon_i^{\mu_1} \pm \epsilon_i^{\mu_2} \pm \epsilon_i^{\mu_3})$$



¿Espuriedad = malo ?



+



=



espurio, ria SIN. / ANT.

Del lat. *spurius*.

1. adj. **bastardo** (Il que degenera de su origen o naturaleza).

SIN.: bastardo, ilegítimo.

ANT.: puro.

2. adj. **falso** (Il fingido).


SIN.: falso, refalsado, ficticio, fraudulento, bamba³.

ANT.: verdadero, auténtico.

hijo **espurio**

—
01

Conclusiones



Conclusiones generales

- Cada red vista está especializada para un tipo de problema particular
 - Trabajarlas para poder utilizarlas en problemas de predicción resulta que sean poco óptimas
- Estos modelos nos demuestran la capacidad de poder aprender incluso en contextos donde no hay una respuesta “correcta” conocida
- Buscamos cierta uniformidad para garantizar la estabilidad de los atractores de Hopfield
- Los estados espurios pueden ser útiles, no necesariamente son interferencia.

Conclusiones generales

- No podremos siempre minimizar los errores. La reducción de uno puede llevar al aumento de otro.
- Oja y Sanger permiten aproximar a la reducción de dimensionalidad que ofrece PCA a una fracción del poder de cómputo
- La implementación actual de Hopfield demuestra potencial, pero limitado

A futuro

- Hopfield: Regla de Storkey, Implementaciones continuas¹
- Oja y Sanger: Extension no lineal

¹Ramsauer, H., Schäfl, B., Lehner, J., Seidl, P., Widrich, M., Adler, T., ... Hochreiter, S. (2021). Hopfield Networks is All You Need. arXiv [Cs.NE]. Retrieved from <http://arxiv.org/abs/2008.02217>

¡Gracias!

CREDITS: This presentation template was created by [Slidesgo](#), and includes icons by [Flaticon](#), and infographics & images by [Freepik](#)

Please keep this slide for attribution