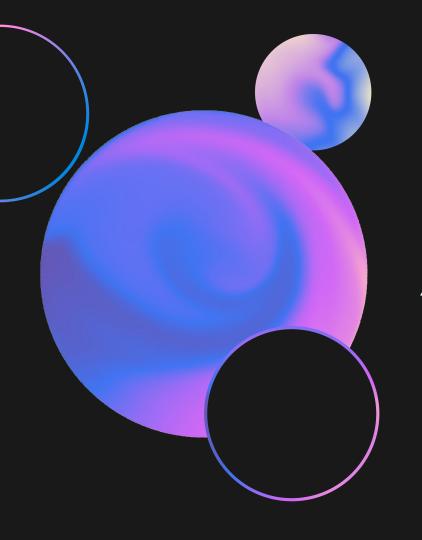
## Autoencoders

Here we go!







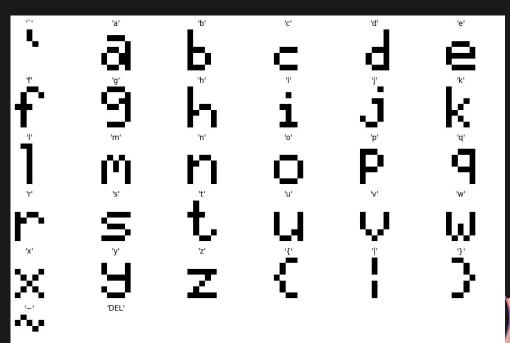
### Autoencoder



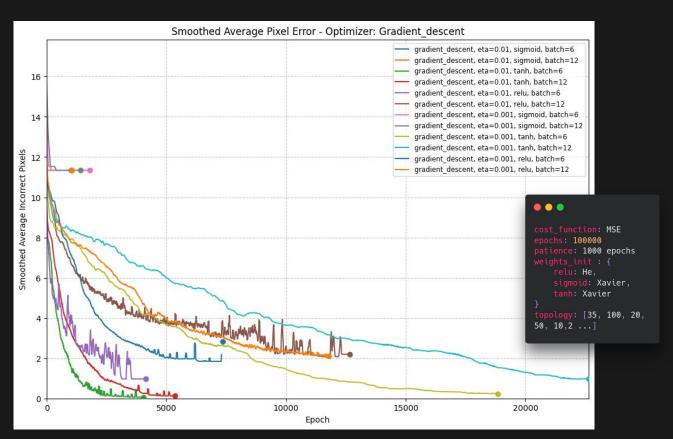


# Dataset e hiperparámetros

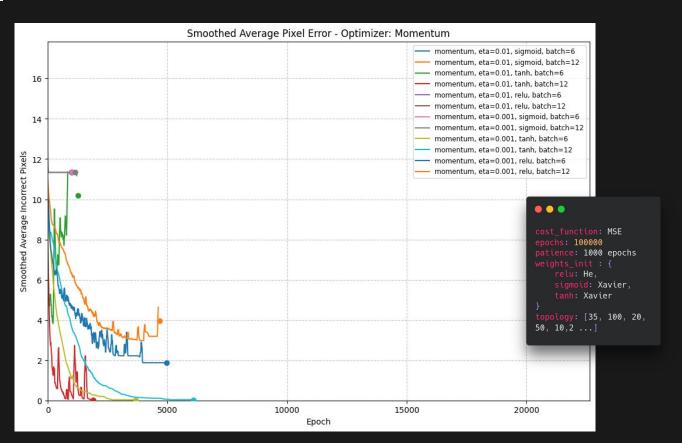
```
cost_function: MSE
epochs: 100000
patience: 1000 epochs
weights_init : {
    relu: He,
        sigmoid: Xavier,
        tanh: Xavier
}
topology: [35, 100, 20,
50, 10,2 ...]
```



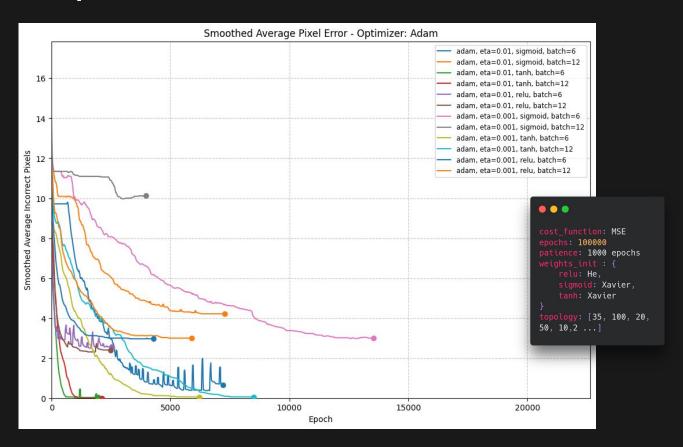
#### Optimizadores - SGD



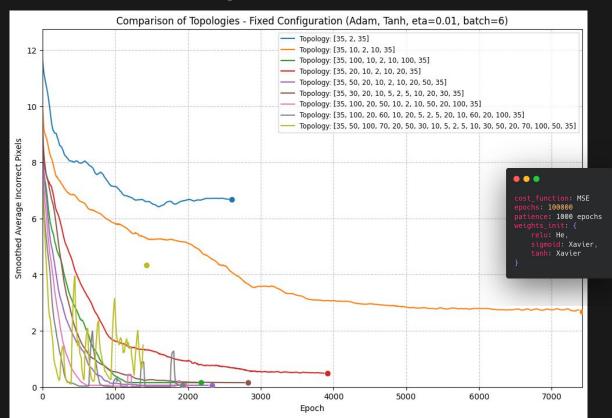
#### Optimizadores - Momentum



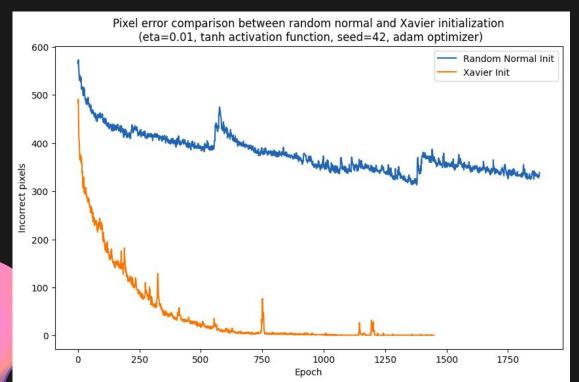
#### Optimizadores - Adam



#### Arquitectura



#### Inicialización



1. ReLU Activation: He Initialization:

$$\mathbf{W}^{(i)} \sim \mathcal{N}(0, \sqrt{\frac{2}{n_i}})$$

where  $n_i$  is the number of neurons in the previous layer.

2. Sigmoid or Tanh Activation: Xavier Initialization:

$$\mathbf{W}^{(i)} \sim \mathcal{N}(0, \sqrt{\frac{1}{n_i}})$$

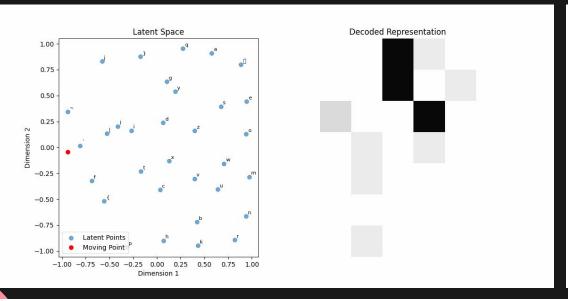
3. Default Initialization: Small standard deviation:

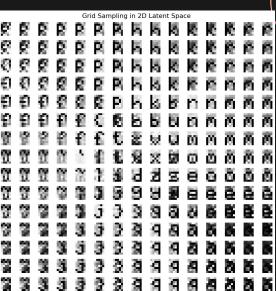
$$\mathbf{W}^{(i)} \sim \mathcal{N}(0, 0.01)$$



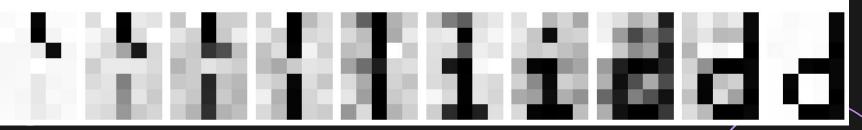


#### Latent Space





Morphing Between Two Latent Points



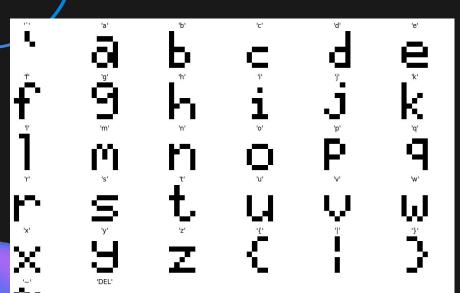


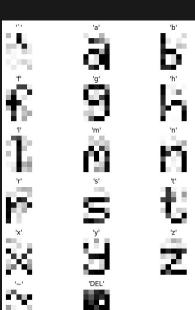
# Proceso y arquitectura

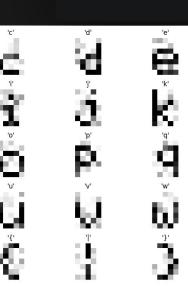


noise: gaussian
activation: tanh
optimizer: adam

seed: 42 std: 0.2







noise: gaussian
activation: tanh
optimizer: adam

Resultados

seed: 42

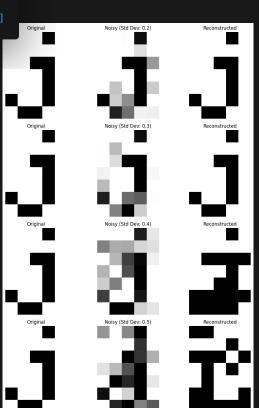
topology: [35, 50, 25, 2, 25, 50, 35]

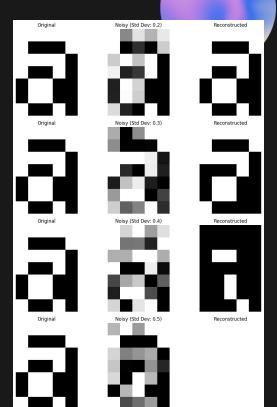
std: 0.2

std: 0.3

std: 0.4

std: 0.5





90.71%

84.91%

78.57%



noise: gaussian activation: tanh optimizer: adam

Resultados

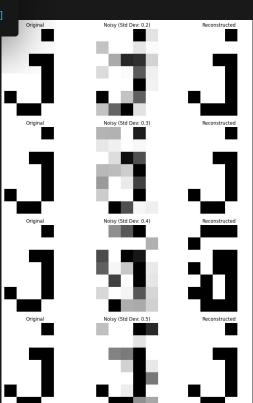
topology: [35, 50, 25, 12, 25, 50, 35]

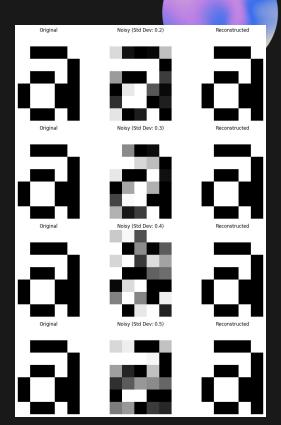
std: 0.2

std: 0.3

std: 0.4

std: 0.5





97.14%

92.23%

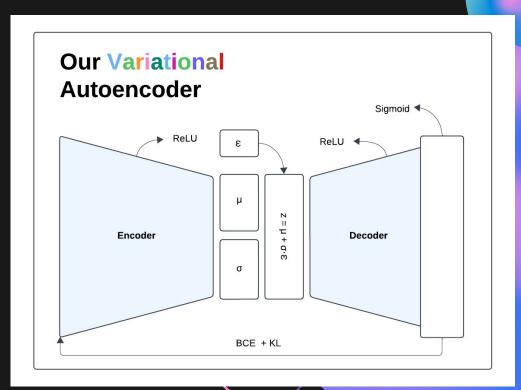
87.05%

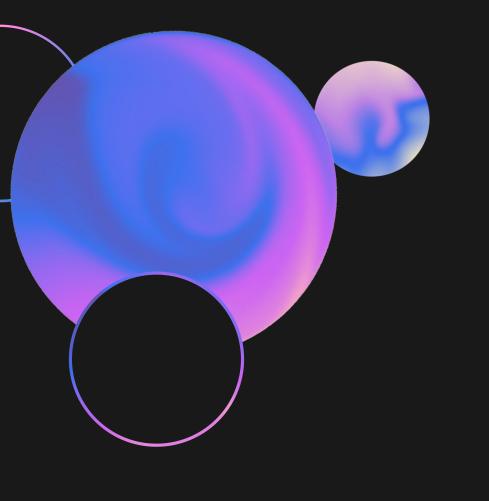




#### ¿En qué se diferencia?

- Modela una distribución probabilística en el entrenamiento.
- Añade pérdida para **asemejar la distribución latente a una gaussiana estándar**.
- Enfocada en la generación y/o interpolación, a diferencia de la extracción de características y encoding robusto.
- Requiere ser entrenada con un dataset limpio, con poco ruido.





# MNIST

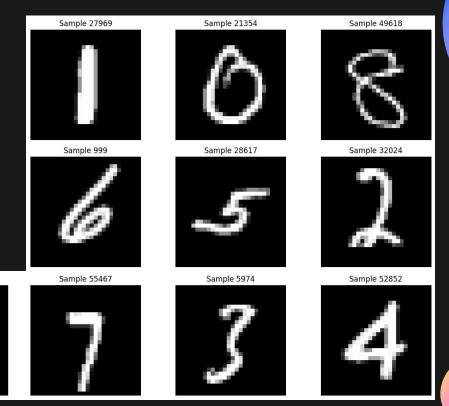


#### Dataset

 28x28 píxeles donde cada uno tiene un valor entre 0 y 255 que se condice con la escala de grises

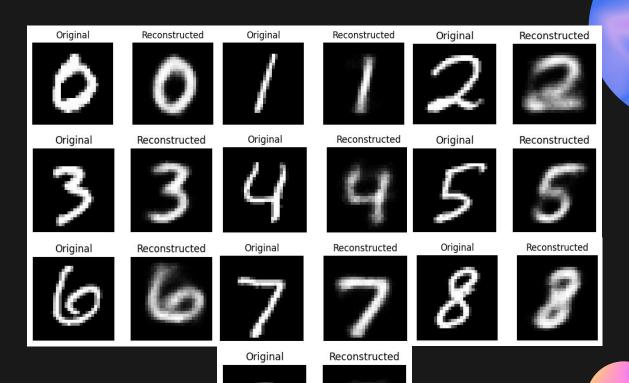
Sample 36922

- 60000 elementos
- 10 conjuntos discretos con poca variabilidad



#### Reconstruction

- Buenas reconstrucciones
- La nitidez depende de qué tan cerca del centroide está

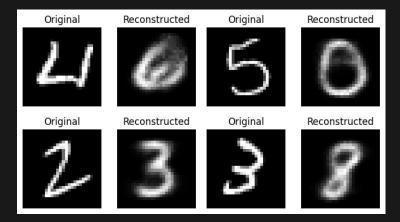


#### Casos excepcionales

#### Denoising

# Original Reconstructed Original Reconstructed Original Reconstructed Original Reconstructed Original Reconstructed Original Reconstructed

#### Hallucinations

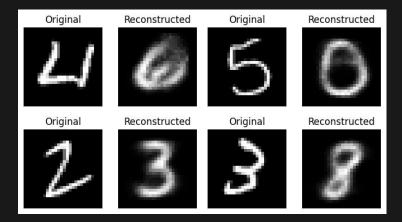


#### Casos excepcionales

#### Denoising

# Original Reconstructed Original Reconstructed Original Reconstructed Original Reconstructed Original Reconstructed Original Reconstructed

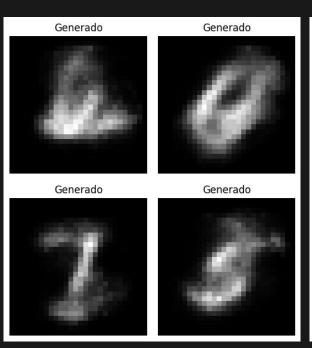
#### Hallucinations



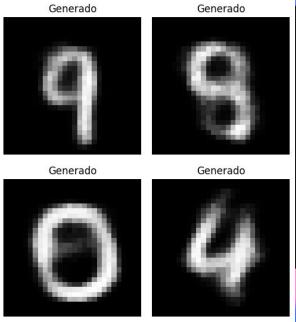
#### Generation

- Como el conjunto de números es discretizado, es muy difícil juzgar la validez de las generaciones
  - Además hay prevalencia de generaciones idénticas a las de entrenamiento, fallando el objetivo de generación.

#### Gusanos



#### **Imitaciones**





# Emojis

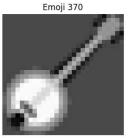


#### Dataset

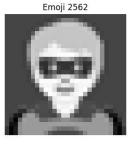
- 28x28 píxeles donde cada uno tiene un valor entre 0 y 255 que se condice con la escala de grises
- 2951 elementos
- Alta variabilidad
- Alta proporción de rostros

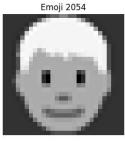
```
seed = 42
encoder_topology = [4900, 500, 300, 128, 64]
decoder_topology = [64, 128, 300, 500, 4900]
optimizer = Adam
activation_fn = ReLU
```

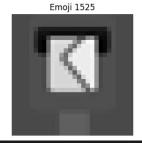


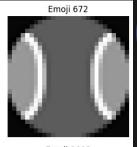




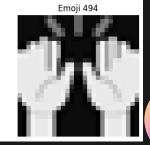






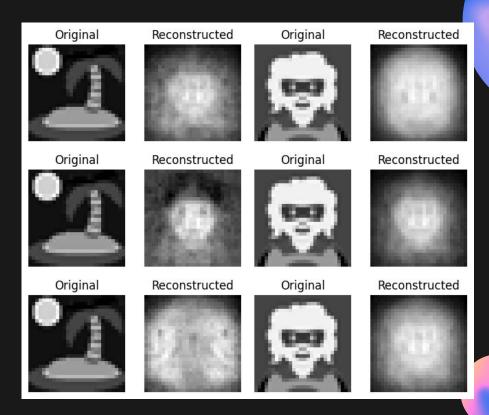






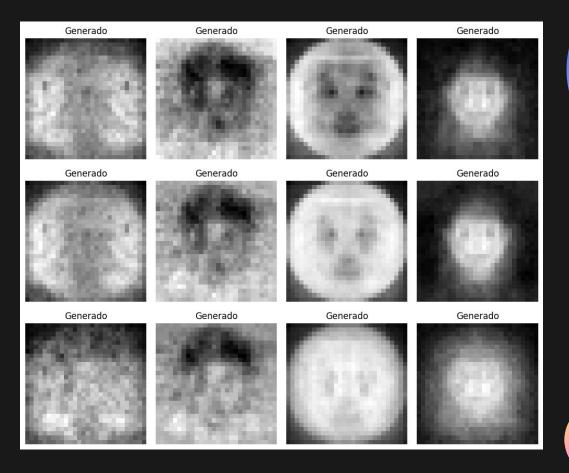
#### Reconstruction

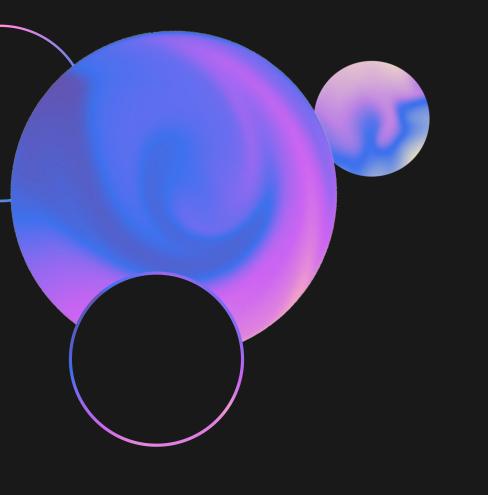
- La diversidad del dataset hace que el vae no reconstruye adecuadamente para prácticamente ningún elemento.
- Un entrenamiento más extenso, una dataset mas grande o una dimensionalidad del espacio latente más alta podrían mejorar el desempeño
- Dadas las limitaciones reducir la variabilidad es lo más viable.



#### Generation

- En general se encontraron estos 4 clusters de generación
- Se puede notar la "intención" del VAE en cada una de las generación
- No logra cumplir el objetivo





### Faces



#### Dataset

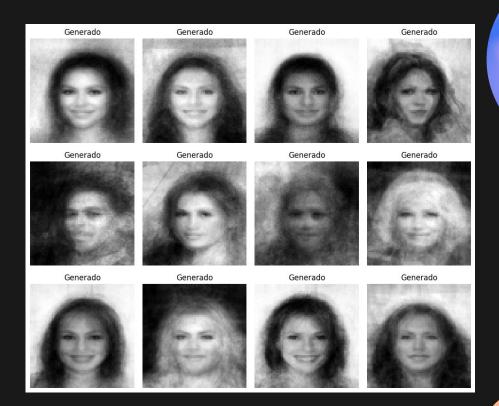
- 70x70 píxeles donde cada uno tiene un valor entre 0 y 255 que se condice con la escala de grises
- 1000 elementos
- Baja variabilidad

```
seed = 42
encoder_topology = [4900, 500, 300, 128, 64]
decoder_topology = [64, 128, 300, 500, 4900]
optimizer = Adam
activation_fn = ReLU
epochs = 500
```

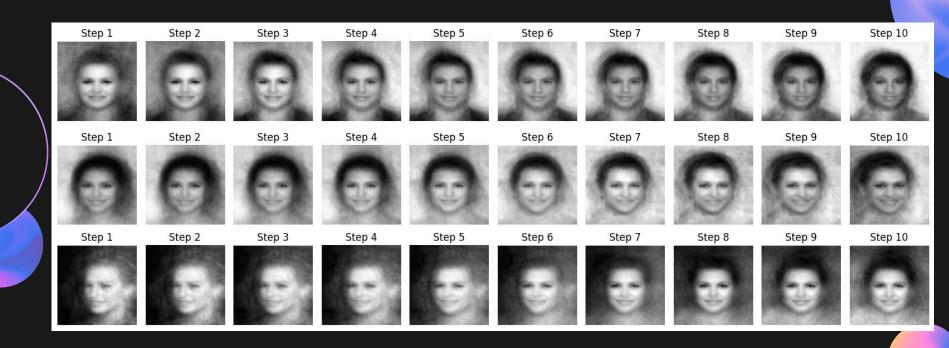


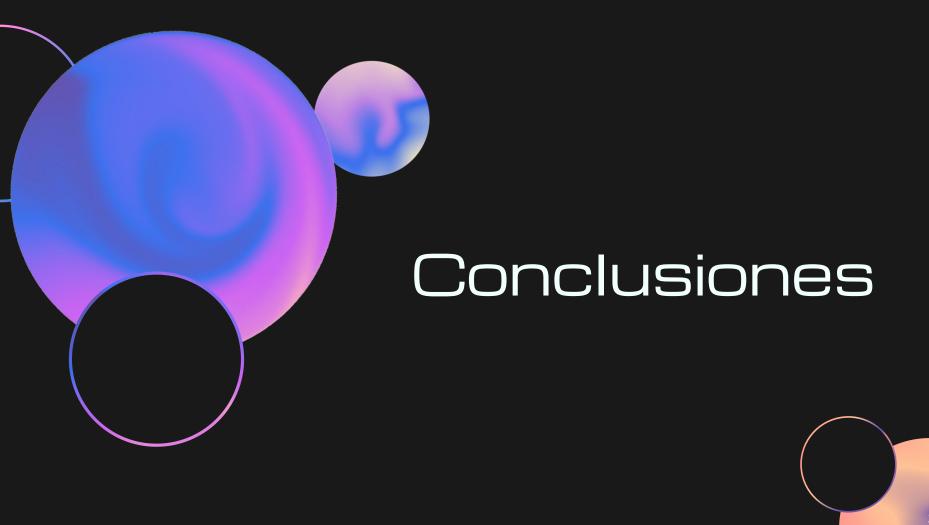
#### Generation

 Logramos conseguir un generador de imágenes aterradoras



#### Generation





#### Conclusiones

- El **aumento de la dimensionalidad** en el espacio latente suele ser **beneficioso** siempre y cuando no se caiga en la **falacia de las dimensiones**.
- La **reducción de dimensionalidad** en el espacio latente puede ayudar a encontrar **patrones** o formas de **agrupar** la información, además de arrastrar los beneficios de otros reductores de dimensionalidad (compresión, visualización de información, etc).
- Como siempre, tamaño y calidad del dataset son factores clave, al igual que el hardware.
- Para el objetivo de **denoising** se vieron resultados muy positivos, los negativos incluso pueden ser utilizados para detección de anomalías.
- Para objetivos generativos existen mejores herramientas que las exploradas, los limitantes probablemente sean otros factores y no la herramienta.
- El **espacio latente** es un **espacio vectorial**, tiene más compresión que un embedding clásico, aun así se puedan explorar operaciones.
- La interpolación a través del espacio latente puede tener algunos usos interesantes con transiciones suaves.

